# Neural Network and Back Propagation

#### **Activation functions**

**Activation Functions** 

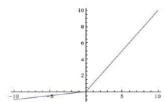
## Sigmoid

$$\sigma(x) = 1/(1 + e^{-x})$$

tanh tanh(x)

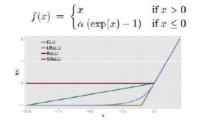
**ReLU** max(0,x)

### Leaky ReLU max(0.1x, x)



 $\textbf{Maxout} \quad \max(w_1^Tx+b_1,w_2^Tx+b_2)$ 

**ELU** 



#### **Gradient Descent**

$$s = f(x; W) = Wx$$

 $L_i = \sum_{j 
eq y_i} \max(0, s_j - s_{y_i} + 1)$ 

SVM loss

scores function

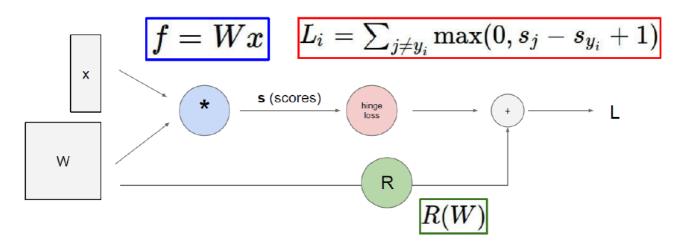
$$L = rac{1}{N} \sum_{i=1}^N L_i + \sum_k W_k^2$$

data loss + regularization

want  $abla_W L$ 

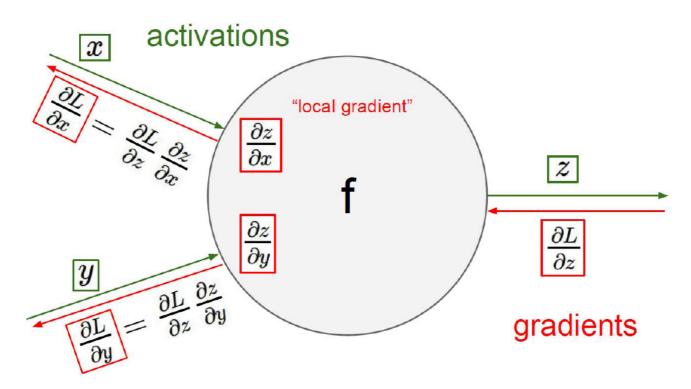
注:对于第三个损失函数, $L_i$  代表单个测试数据的损失; $\sum_k W_k^2$  代表对权重的累加,这是一种正则化的方法,因为我们有很多种W可以选择,但太过复杂的W可能导致过拟合,因此使用这种方式可以使模型选择简单的W。最后我们希望求出梯度。

## **Computational Graph**



上面是 SVM 的计算图,R(W) 就是上面的  $\sum_k W_k^2$ 。

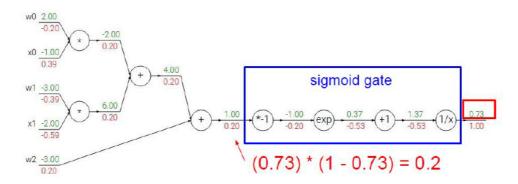
#### **BP**



上面是BP算法中chain rule的一个示例。

$$f(w,x)=rac{1}{1+e^{-(w_0x_0+w_1x_1+w_2)}}$$
  $\sigma(x)=rac{1}{1+e^{-x}}$  sigmoid function

$$rac{d\sigma(x)}{dx} = rac{e^{-x}}{\left(1 + e^{-x}
ight)^2} = \ \left(rac{1 + e^{-x} - 1}{1 + e^{-x}}
ight) \left(rac{1}{1 + e^{-x}}
ight) = \ \left(1 - \sigma(x)
ight)\sigma(x)$$



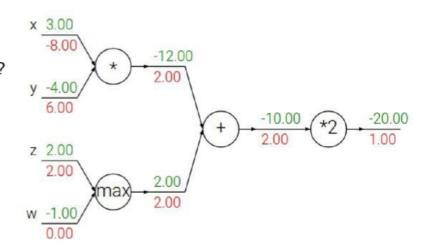
这里可以把 sigmoid 部分看作一个整体,求出梯度。

#### Patterns in backward flow

add gate: gradient distributor

max gate: gradient router

mul gate: gradient... "switcher"?



加法门:梯度分配器,分配相同的梯度值。

最大值门: 梯度路由, 反向传播时, 它会把梯度值分配给输入值最大的线路。

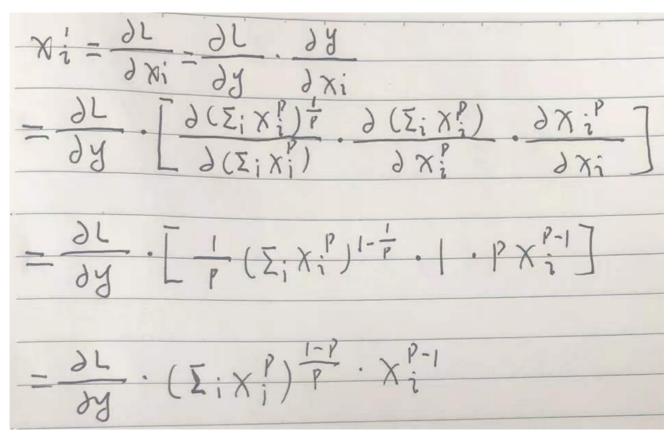
乘法门:梯度转换器,把梯度转换成不一样的值。

#### **Exercise**

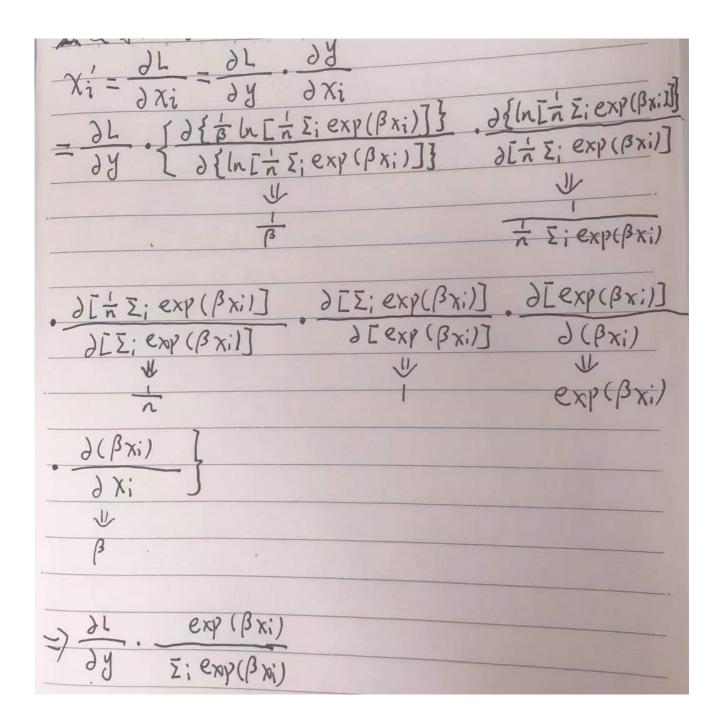
Pooling units take n values  $x_i$ ,  $i \in [1, n]$  and compute a scalar output whose value is invariant to permutations of the inputs.

- 1. The Lp-pooling module takes positive inputs and computes  $\mathbf{y} = (\sum_i x_i^p)^{\frac{1}{p}}$ , assuming we know that  $\mathbf{y}' = \frac{\partial L}{\partial \mathbf{y}}$ , what is  $x_i' = \frac{\partial L}{\partial x_i}$ ?
- 2. The log-average module computes  $y=\frac{1}{\beta}\ln(\frac{1}{n}\sum_{i}\exp(\beta x_{i}))$ , assuming we know that  $y'=\frac{\partial L}{\partial y}$ , what is  $x'_{i}=\frac{\partial L}{\partial x_{i}}$ ?

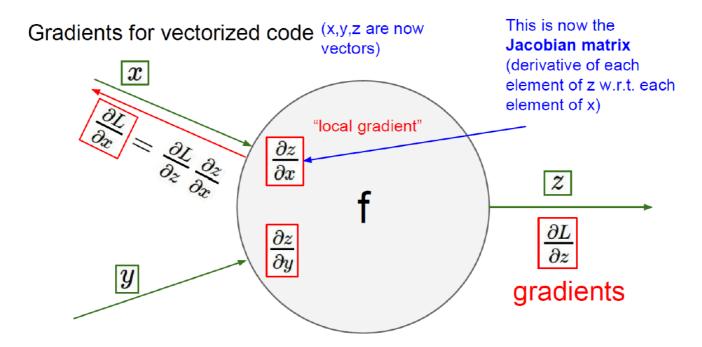
第一问:



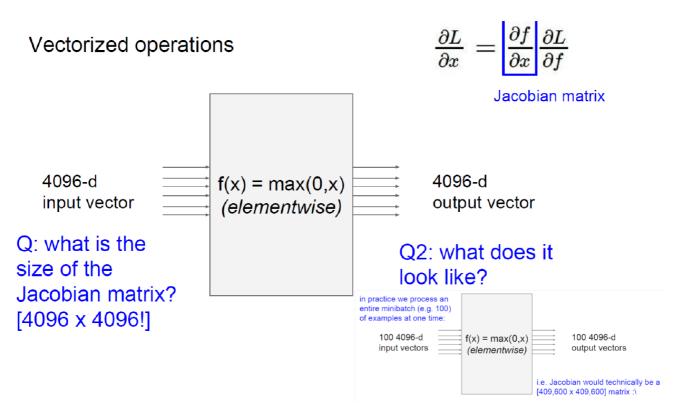
第二问:



**Gradients for vector** 



之前输入单个值的时候,梯度是单个值;现在输入的是向量,梯度也变成同等大小的向量,即 jacobian matrix (其中是 local gradient)。



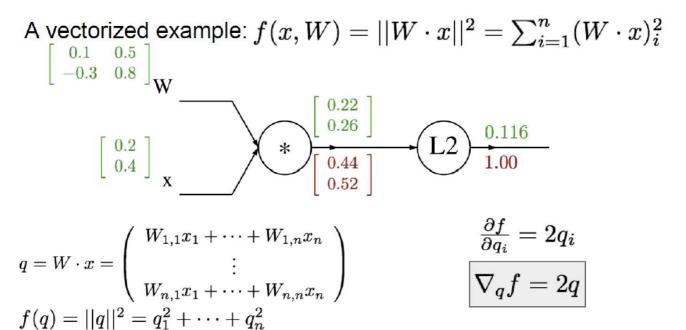
注: jacobian matrix 的 shape 和输入的 shape 一致。

如下面的例子所示, 我们对其进行 BP 算法:

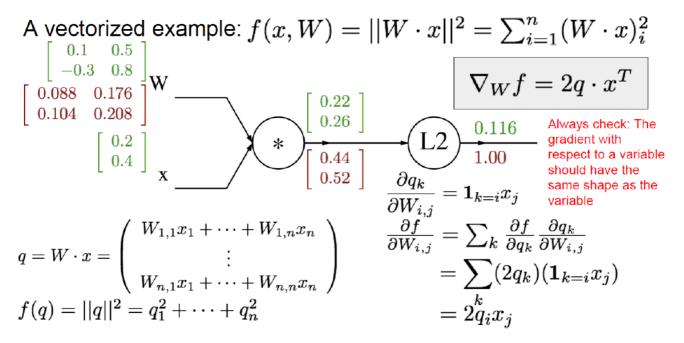
A vectorized example:  $f(x,W)=||W\cdot x||^2=\sum_{i=1}^n(W\cdot x)_i^2$   $\begin{bmatrix} 0.1 & 0.5 \\ -0.3 & 0.8 \end{bmatrix}_W$   $\begin{bmatrix} 0.22 \\ 0.4 \end{bmatrix}_X$   $\begin{bmatrix} 0.22 \\ 0.26 \end{bmatrix}$ 

$$q = W \cdot x = \begin{pmatrix} W_{1,1}x_1 + \dots + W_{1,n}x_n \\ \vdots \\ W_{n,1}x_1 + \dots + W_{n,n}x_n \end{pmatrix}$$
$$f(q) = ||q||^2 = q_1^2 + \dots + q_n^2$$

前向传播之后,进行反向传播:



之后求 W 的梯度:



注:比如要求 $W_{1,1}$ 的梯度,包含 $W_{1,1}$ 的式子只有 $q_1$ ,因为 $q_1=W_{1,1}x_1+\dots W_{1,n}x_n$ 。因此,可以得到: $\frac{\partial f}{\partial w_{i,j}}=\frac{\partial f}{\partial q_k}\cdot \frac{\partial q_k}{\partial w_{i,j}}=2q_kx_j$ 。

最后是 x 的梯度:

注:比如要求 $x_1$ 的梯度,所有q中都包含 $x_1$ 。因此我们要考虑所有的q。

包含  $x_1$  的式子:  $f=(w_{1,1}x_1)^2+\ldots+(w_{n,1}x_1)^2$ ,我们要求这个式子对  $x_1$  的偏导,就要求出每一个的偏导,再相加。先求  $q_1$  中  $x_1$  的偏导:  $\frac{\partial q_1}{\partial x_1}=2(w_{1,1}x_1)w_{1,1}=2q_1w_{1,1}$ 。

对每一个 q 都这样操作, f 对  $x_1$  的偏导最后就是:

$$rac{\partial f}{\partial x_1} = 2q_1w_{1,1} + \ldots + 2q_nw_{n,1} = \sum_k 2q_kW_{k,1}$$
 ,

因此,对于i个x,最后就得到了 $\sum_{k} 2q_{k}W_{k,i}$ 。